压缩态内存数据库实时算法设计与实现 项目需求分析说明书

V1.0

小组名称: Never give up 小组口号: Make the change

指导教师:赵振刚老师 **文档撰写人:**刘勇

文档撰写时间: 2013年11月15日



团队分工记录表

项目名称	学号	姓名	分工
压缩态内存数据	SG13225025	蓝鸿翔	
库实时算法设计 与实现	SA13226282	刘勇	需求分析说明书编写
\$2100	SG13225022	范亚林	

目录

1.	前言	3
	1.1 目的和范围	3
	1.2 内存数据库与传统数据库的区别	3
	1.3 列式数据库与行式数据库的优缺点	4
2.	系统概述	4
3.	设计目标	4
4.	需求分析	5
	3.1 功能需求分析	5
	3.2 技术需求分析	7
	3.2.1 开发环境	7
	3.2.2 技术难点分析	7
5.	参考资料	8

1. 前言

1.1 目的和范围

压缩态内存数据库是基于列式存储的内存数据库,具有传统数据库的通用功能特性,即增删改查等操作,但是将数据导入内存中操作的。本说明书的主要目的是明确所要开发的系统应具有的功能、性能,使系统分析人员和软件设计人员能清楚地了解用户的需求,并在此基础上进一步提出概要设计和完成后续设计与开发工作,为软件开发范围、业务处理规范提供依据,也是应用软件进行最终验收的依据。

其应用范围见表 1:

读者分类	目的
客户代表	了解本文档对需求的理解是否和他们要求的一致
系统分析人员	理解用户需求,转化为系统需求
系统设计人员	理解用户,在设计时把握用户需求
系统测试人员	了解用户需求,为测试提供参考
文档人员	编写用户使用和操作手册

表1本文档应用范围

1.2 内存数据库与传统数据库的区别

内存数据库,顾名思义就是将数据放在内存中直接操作的数据库。相对于磁盘,内存的数据读写速度要高出几个数量级,将数据保存在内存中相比从磁盘上访问能够极大地提高应用的性能。

传统的数据库系统是关系型数据库,开发这种数据库的目的,是处理永久、稳定的数据。 关系数据库强调维护数据的完整性、一致性,但很难顾及有关数据及其处理的定时限制,不 能满足工业生产管理实时应用的需要,因为实时事务要求系统能较准确地预报事务的运行时 间。

对磁盘数据库而言,由于磁盘存取、内外存的数据传递、缓冲区管理、排队等待及锁的延迟等使得事务实际平均执行时间与估算的最坏情况执行时间相差很大,如果将整个数据库或其主要的"工作"部分放入内存,使每个事务在执行过程中没有 VO,则为系统较准确估算和安排事务的运行时间,使之具有较好的动态可预报性提供了有力的支持,同时也为实现事务的定时限制打下了基础。这就是内存数据库出现的主要原因。

内存数据库所处理的数据通常是"短暂"的,即有一定的有效时间,过时则有新的数据产生,而当前的决策推导变成无效。所以,实际应用中采用内存数据库来处理实时性强的业务逻辑处理数据。而传统数据库旨在处理永久、稳定的数据,其性能目标是高的系统吞吐量和低的代价,处理数据的实时性就要考虑的相对少一些。实际应用中利用传统数据库这一特性存放相对实时性要求不高的数据。

1.3 列式数据库与行式数据库的优缺点

传统的行式数据库,是按照行存储的,维护大量的索引和物化视图无论是在时间(处理)还是空间(存储)方面成本都很高。而列式数据库恰恰相反,列式数据库的数据是按照列存储,每一列单独存放,数据即是索引。只访问查询涉及的列,大大降低了系统 VO,每一列由一个线来处理,而且由于数据类型一致,数据特征相似,极大方便压缩。行式数据库擅长随机读操作,列式数据库则更擅长大批量数据量查询。

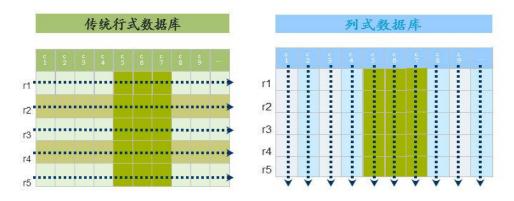


图 1: 传统行式数据库的列式数据库

2. 系统概述

本文档适用于压缩态内存数据库实时算法设计与实现项目。压缩态内存数据库是数据放在内存中直接操作,同时根据数据库的列属性特性进行压缩的数据库。

近年来,电信行业和金融行业日益增长的对实时数据处理的需求,传统的磁盘数据库逐渐不能满足这些应用需求。内存数据库的出现解决了事物处理的实时性要求。

目前市场上内存数据库的产品有 Oracle 公司的 TimesTen, Sybase 公司的 Sybase ASE, 开源内存数据库 SQLite。

与此同时,由于 21 世纪数据的爆炸性的增长、如何对数据进行管理,引出了两大分支:数据压缩技术、数据库管理技术。所以本系统不仅采用内存数据库解决实时性问题,而且采用列压缩方案,解决数据量和存储空间的矛盾。

3. 设计目标

设计实现一个基于列压缩的内存数据库。该内存数据库支持一下功能:

- (1) 适用于海量数据的大型服务器。
- (2) 采用数据压缩,压缩比达到 0.1。
- (3) 相对于 Sqlite, 存取时间能下降 3%以内。
- (4) 支持 增加删除修改查询等操作
- (5) 适用于查询密集型用户

4. 需求分析

4.1 功能需求分析

我们所要设计的压缩态内存数据库所具有的功能大体上有如下几点:

■ 数据导入模块:

导入测试数据或者是系统其他数据。工程过整个过程中都需要使用大量数据进行模拟,这个部分实现根据工程要求随机产生大量的符合属性的各种类型数据包括整型、字符、字符串、时间、文件等类型的数据。并且利用标准化的导入接口把硬盘数据导入到内存以形成固定格式进行存储,并且提供标准的接口把数据导入到数据库中。

■ 列属性统计模块:

哈希统计数据库文件的每列数据的数据属性特征。

■ 压缩算法调度模块:

根据每列的数据特性, 计算采用不同压缩方案的空间使用情况, 从而抉择最佳的压缩算法。

■ 数据压缩模块:

该模块是本系统的核心模块。

(1) 游程压缩:用一个符号值或串长代替具有相同值的连续符号(连续符号构成了一段连续的"行程"。行程编码因此而得名),使符号长度少于原始数据的长度。只在各行或者各列数据的代码发生变化时,一次记录该代码及相同代码重复的个数,从而实现数据的压缩。

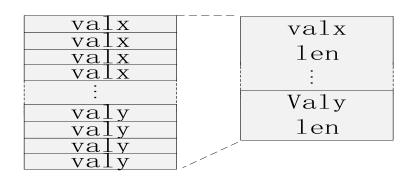


图 2: 游程压缩思想

(2) 字典压缩:字典压缩的原理是构建一个字典,用索引来代替重复出现的字符或字符串,字符串重复率越高,压缩效率越高。

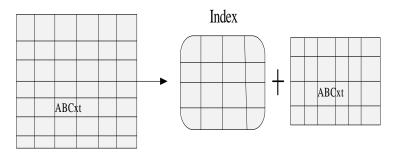


图 3: 字典压缩思想

(3) Bit 压缩:对于在一个范围内连续不重复的数据,采用 bit 数组来表示,从而达到压缩的目的。

1
2
3
4
5
6

1
1
1
1
О
1

图 4: Bit 压缩思想

(4) 空值悬挂:对列中的空值,用标记每列是否为空。

■ 数据操作模块:

支持原始数据和列式存储的压缩数据的增加、删除、修改、查询记录等操作。

■ 数据导出模块:

在内存中实现数据的压缩,并支持压缩后的数据的导出与备份。

4.2 技术需求分析

4.2.1 开发环境

开发环境:

- 宿主机操作系统: Ubuntu 12.04
- 开发工具: VIM, GDB
- 对比数据库: Sqlite
- 编程语言: C/C++

4.2.2 技术难点分析

(1) 如何对压缩态数据进行删除和修改等操作:

在列式压缩存储的数据库中,不适合数据的修改和修改插入等操作。但是为了 实现数据库的通用性,对于数据的插入等需要采用一些折中的方法来实实现这个难题。

解决方案:

- A. 原表分配内存的时候进行预留空间的方式,把数据的修改,插入转换都转化为数据的删除和插入的的方式添加到表的最后面。
- B. 新添加的数据以原始态的形式保存在新表中,当插入的数据达到一定的阀值,在进行压缩等。
- (2) 如何加快列式数据库的查询效率:

由于本系统采用的是列式数据库,针对查询密集型用户,所以查询时间对用户来说至关重要。

解决方案:

A. 改进数据结构,增加列间指针进行索引。

5. 参考资料

- [1] 荣垂田.一个内存数据库模型的设计与实现 [D].辽宁: 中国科学院沈阳计算技术研究 所, 2008
- [2] 王珊 肖艳芹等.内存数据库关键技术研究. 计算机应用[J] Vol.27 2007(10):2354-2355
- [3] 数据库系统概念 Abraham Silberschatz ,Henry E Korth S.Sudarshan 著,杨冬青唐世渭等译,机械工业出版社,2003:244
- [4] James E Kurose, Keith W. Ross 著,陈鸣译.计算机网络-自顶向下方法与 Internet 特色[M].北京: 机械工业出版社,2006
 - [5] 黄 鹏,李占山等.基于列存储数据库的压缩态数据访问算法[D].吉林: 吉林大学, 2009
- [6] 马洪连 杨 波等.一个适用于内存数据库系统的多维索引结构[D]. 辽宁:大连理工大学,2003
- [7] 俞甲子,石凡,潘爱民.程序员的自我修养:链接、装载与库[M].电子工业出版社, 2009:32-90